

Описание:

Пример данных состоит из 3 примеров документов:

1. Описание потоков данных.
2. Описание данных системы источника.
3. Описание витрины-агрегата.

Все данные в документах обезличены.

Основная цель – разработать систему, которая бы могла от лица аналитика, разработчика или тестировщика анализировать документацию и указывать места, которые нужно дополнить/скорректировать.

Основные места, на которые надо обратить внимание:

1. Описание расположения источников и Kafka-кластеров.
2. Описание полей и логики их расчета.
3. Описание фильтрации данных.
4. Описание обновления и объема данных.

Тестирование работы алгоритма будет проходить на новом документе по описанию витрины-агрегата.

Работа носит творческий характер и направлена в целом на развитие компетенций в сфере сопровождения документацией объектов данных.

Метрика – качественный показатель указания на дополняемые моменты.

В случае необходимости, документацию для обучения можно брать любую другую – например, из открытого доступа.

Общие сведения

Модуль обеспечивает получение сведений о текущем и историческом местоположении абонентских устройств в реальном времени. Обработка основана на сигнальном трафике сетей радиодоступа (3G/4G), поступающем от платформы PROVIDER_GEO.

Решаемая проблема

Замена устаревшей технологии геолокации абонентов по данным радиоинтерфейса. Цель — создание отечественного решения с потоковой обработкой и интеграцией в Data Lake.

Продуктовые метрики

- Задержка: < 1 мин
- Пропускная способность: до 100 000 событий/сек
- Точность локации: 3G — 50–500 м, 4G — 10–100 м

Заказчики

BigData Unit X

Нефункциональные требования

- Инкрементная загрузка по часовым партициям
- Географическое разбиение по регионам
- Стриминг в реальном времени (задержка ≈ 0 сек)
- Хранение: Kafka — 24 ч, RAW-слой — 30 дней

Системы-источники

- PROVIDER_GEO — мультивендорная платформа агрегации событий 3G/4G и MDT.

Схема потоков данных

PROVIDER_GEO → Kafka (топики по регионам) → Apache Flink → RAW → DDS → ADDS → CDM

- Мониторинг: LINK_DASHBOARD_GEO
- Исходный код: LINK_GITLAB_PROJECT

JIRA

PROJECT-XX123 — Описание потоковой обработки геоданных
LINK_JIRA_TASK

Команда

- USER_A — Product Owner
- USER_B — Data Analyst
- USER_C — Backend Developer

Источники и приемники данных

PROVIDER_GEO → Kafka (24 часа хранения):

Регион	Топик 3G	Топик 4G
Центр	TOPIC_GEO3G_CENTRAL	TOPIC_GEO4G_CENTRAL
Дальний Восток	TOPIC_GEO3G_EAST	TOPIC_GEO4G_EAST
Северо-Запад	TOPIC_GEO3G_NW	TOPIC_GEO4G_NW
Поволжье	TOPIC_GEO3G_VOLGA	TOPIC_GEO4G_VOLGA
Сибирь	TOPIC_GEO3G_SIB	TOPIC_GEO4G_SIB
Юг	TOPIC_GEO3G_SOUTH	TOPIC_GEO4G_SOUTH
Урал	TOPIC_GEO3G_URAL	TOPIC_GEO4G_URAL

Приемники:

Слой	Таблица	Описание
RAW	TABLE_GEO_RAW_3G	Данные по 3G (необработанные)
RAW	TABLE_GEO_RAW_4G	Данные по 4G (необработанные)
DDS	TABLE_GEO_DDS_DETAILED	Детальные события геолокации
ADDS	TABLE_GEO_ADDS_AGG	Агрегированные события
CDM	TABLE_GEO_CDM_INTERVALS	Геоинтервалы по абонентам

Структура данных

Таблица: TABLE_GEO_RAW_3G

Поле	Тип данных	Описание
FIELD_REGION	string	Регион
FIELD_DATE_EVENT	date	Дата события
FIELD_HOUR	int	Час события (партиция)
FIELD_IMSI	string	IMSI
FIELD_MSISDN	string	MSISDN
FIELD_IMEI	string	IMEI
FIELD_LAT	double	Широта геопозиции
FIELD_LON	double	Долгота геопозиции
FIELD_RADIUS	int	Радиус точности (метры)
FIELD_CELL_START	long	ID начальной базовой станции
FIELD_CELL_END	long	ID конечной БС
FIELD_TIME_START	long	Время начала события
FIELD_TIME_END	long	Время окончания события
FIELD_LOC_ACCURACY	int	Точность локации (метры)
FIELD_VENDOR	string	Вендор оборудования БС

Таблица: TABLE_GEO_RAW_4G

Поле	Тип данных	Описание
FIELD_REGION	string	Регион
FIELD_DATE_EVENT	date	Дата события
FIELD_HOUR	int	Час события (партиция)
FIELD_IMSI	string	IMSI
FIELD_MSISDN	string	MSISDN

FIELD_IMEI	string	IMEI
FIELD_LAT	double	Широта геопозиции
FIELD_LON	double	Долгота геопозиции
FIELD_RADIUS	int	Радиус точности (метры)
FIELD_CELL_START	long	ID начальной БС
FIELD_CELL_END	long	ID конечной БС
FIELD_TIME_START	long	Время начала события (Unix-время)
FIELD_TIME_END	long	Время окончания события
FIELD_SERVICE_TYPE	int	Тип формата связи (услуга)

Дополнительная информация

Документы:

- «Описание протоколов сигнальных сообщений в 3G/4G»
- «Форматы MDT и Measurement Trigger»

Алгоритмы: обработка хэндоверов, геоинтервалов, работа с RNC/eNodeB.

Общие сведения

Платформа обслуживает prepaid-абонентов. Файлы, поступающие с системы, содержат телеком-события абонентов, заведённых на платформе.

Заказчики

BigData

Системы-источники

PI_System — система сбора CDR-файлов с сетевых элементов подвижной связи.

Команда

- USER_A — Product Owner
- USER_B — Data Analyst
- USER_C — Backend Developer

Источники и приёмники данных

Источники (CDR в формате CSV, сжатые gzip)

Данные поступают в Kafka по топикам, соответствующим регионам:

Регион	Kafka-топик	SFTP-папка HDFS
Центр	TOPIC_MSCP_CDR_CENTRAL	Папка
Дальний Восток	TOPIC_MSCP_CDR_EAST	Папка
Сибирь	TOPIC_MSCP_CDR_SIB	Папка
Северо-Запад	TOPIC_MSCP_CDR_NW	Папка
Поволжье	TOPIC_MSCP_CDR_VOLGA	Папка
Юг	TOPIC_MSCP_CDR_SOUTH	Папка

Приёмники:

- TABLE_MSCP_RAW_KFK — необработанные CDR из Kafka (ORC)
- TABLE_MSCP_RAW_SFTP — необработанные CDR из SFTP (CSV)

Алгоритм обработки потока

Шаг 1. Фильтрация данных

Учитываются только события, произошедшие не ранее 7 дней назад и не позже 2 часов вперёд от текущего времени (на стороне обработки).

Шаг 2. Преобразования на потоке

Очистка числовых строк от лидирующих нулей:

Из этих полей удаляются лидирующие нули до первого значимого символа.

Коррекция часового пояса для временных меток:

- Для региона east: 7 часов
- Для регионов central, nw, volga, south: 3 часа

- Примечание: регион sib соответствует east.

Структура данных

Таблица: TABLE_MSCP_RAW_KFK
(из Kafka, ORC-формат, 15 полей)

Поле	Тип данных	Описание
FIELD_REGION	string	Название региона
FIELD_BIZ_DATE	date	Бизнес-дата события
FIELD_HOUR	int	Часовая партиция
FIELD_IMSI	bigint	IMSI
FIELD_CALLING_NUMBER	string	Номер вызывающего абонента
FIELD_CALLED_NUMBER	string	Номер вызываемого абонента
FIELD_CALL_START_TIME	timestamp	Время начала вызова
FIELD_CALL_END_TIME	timestamp	Время окончания вызова
FIELD_CALL_DURATION	int	Длительность вызова (сек)
FIELD_IS_ROAMING	string	Признак роуминга (true/false)
FIELD_OL_SERVICE_TYPE	tinyint	Тип сервиса
FIELD_TIME_ZONE_SHIFT	string	Сдвиг часового пояса
FIELD_TIMEZONE_CALC	int	Вычисленный сдвиг в минутах
FIELD_BALANCE	double	Текущий баланс абонента
FIELD_BALANCE_EXPIRE	timestamp	Срок истечения баланса

FAQ (обобщённо, без реальных ссылок)

Тип события (голос, SMS, данные):

Определяется по FIELD_OL_SERVICE_TYPE (см. выше).

Определение технологии связи (2G/3G/4G/5G):

Для data-трафика — по полю radioAccessTechnology.

Для голоса и SMS — косвенно: по наличию/отсутствию полей геолокации (например, CELL_ID, LAC).

Общие сведения

Агрегат по устройствам абонентов: ежемесячная сводка по вендорам устройств и регионам пользователей.

Бизнес-требования

Название таблицы: TABLE_AGG_DEVICES

Кластер: CLUSTER

Схема: SCHEMA_CDM_NETS

Системы-источники

IUM — IN-платформа (сбор событий интернет-трафика, звонков и SMS)

Способ загрузки

Инкремент

Регламент

Ежемесячно (1 раз в месяц)

Глубина данных

С 01.05.2023

Обязательно загрузить исторические данные.

Команда

- PO: USER_A
- TechPM: USER_B
- Аналитик: USER_C
- Разработчик: USER_D
- QA: USER_E

Заказчики

MVNO Unit X

1. Источники данных

Схема	Таблица	Описание
SCHEMA_RAW	TABLE_IUM_RAW_PS	Необработанные данные по интернет-трафику (GPRS)
SCHEMA_RAW	TABLE_IUM_RAW_MS	Необработанные данные по звонкам и SMS
SCHEMA_ADDS	TABLE_BS_REF	Справочник базовых станций
SCHEMA_DIC	TABLE_REGION_REF	Справочник регионов
SCHEMA_DIC	TABLE_DEVICE_REF	Справочник устройств

2. Структура данных CDM

Таблица: TABLE_AGG_DEVICES

Номер	Поле	Тип данных	Описание	Комментарий
1	FIELD_REGION_NAME	string	Название региона	Определяется как последнее значение region_name за месяц для абонента: сначала по (lac, cell), затем fallback-логика (см. алгоритм).
2	FIELD_VENDOR_NAME	string	Наименование вендора устройства	substring(imei, 1, 8) = tac → vendor_name.
3	FIELD_USERS_CNT	bigint	Уникальное количество абонентов (IMSI)	count(distinct FIELD_IMSI)
4	FIELD_PROC_TS	timestamp	Дата/время создания агрегата	Метка обработки DAG
5	FIELD_BIZ_DATE	date	Бизнес-дата (1-е число месяца, за который формируется агрегат)	Пример: для периода 01.07.2023–31.07.2023 → 2023-07-01

Алгоритм расчёта

Шаг 1. Выбор пользователей

Берутся все уникальные FIELD_IMSI из:

- TABLE_IUM_RAW_MS (SMS + звонки)
- TABLE_IUM_RAW_PS (GPRS) за период: FIELD_BIZ_DATE (месяц).

Шаг 2. Определение вендора

Для каждого FIELD_IMSI берётся FIELD_IMEI (последний по времени за месяц).

Извлекается tac = substring(imei, 1, 8).

Присоединяется FIELD_VENDOR_NAME по tac из TABLE_DEVICE_REF.

Шаг 3. Определение региона

Для каждого FIELD_IMSI за месяц:

Находится последняя запись с ненулевыми FIELD_LAC и FIELD_CELL_ID (по FIELD_TIME_STAMP).

Сопоставление с TABLE_BS_REF: приоритет: (lac, cell_id)

- по lac (последняя актуальная запись за месяц)
- по cell_id только для 4G (FIELD_CELL_GEN = 4)

- если lac = 0 → джойн только по cell_id (4G)
- если cell = 0 → джойн только по lac

Убираются дубли: на выходе — одна region_code на абонента.

Присоединение FIELD_REGION_NAME из TABLE_REGION_REF.

Шаг 4. Агрегация

Группировка по:

- FIELD_REGION_NAME
- FIELD_VENDOR_NAME
- FIELD_USERS_CNT = count(distinct FIELD_IMSI)

Шаг 5. Запись в CDM

Требования к агрегату

Требование	Значение
Регламент расчёта	Ежемесячно
Период агрегации	Календарный месяц
Глубина данных	Исторические данные — с 01.05.2023
Региональная агрегация	Да (по региону)
Часовой пояс	UTC
Поле партиционирования	FIELD_BIZ_DATE
Обновление	Только полная перезагрузка месяца (без upsert)